TP4 — Perception visuelle

Choisir le bon graphique à partir de la question · Séance S04 · données NYC Taxi (janvier 2025)

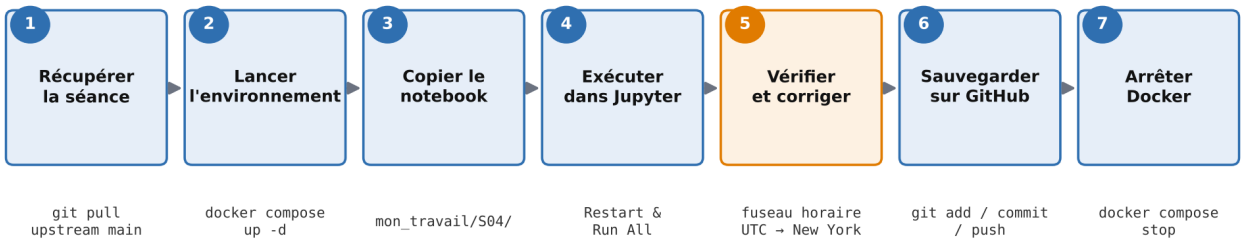
Objectif : savoir choisir le bon graphique pour une question donnée, et justifier chaque choix (type de graphique, axes, couleurs, titre).

Fichier : `mon_travail/S04/04_perception.ipynb` (copie du notebook du prof `seances/S04-perception/`)

Les 3 consignes du TP

#	Consigne	Ce qu'on a fait	État
1	**Atelier « makeover »** : graphiques A, B, C	Question visée, défauts, version refaite pour chacun	✓ fait
2	**Choisir le graphique** : 3 questions de la partie 3	Q1 heure du pic · Q2 top 10 zones · Q3 distance/heure, titres = conclusion	✓ fait
3	**Revue croisée** avec une autre équipe	Un point fort + un point à améliorer chacun	en classe

Le déroulé, étape par étape



En orange : l'étape imprévue — le décalage d'heure découvert en lisant les graphiques.

Schéma 1 — Les 7 étapes du TP, avec la commande associée à chacune.

À vérifier à la fin (diapo du prof) : aucun axe de barres ne commence ailleurs qu'à zéro ; chaque couleur a un sens ; chaque titre énonce une conclusion.

1. Ce que l'œil lit bien

Cleveland et McGill (1984) ont mesuré avec quelle précision on compare deux quantités selon la façon dont elles sont dessinées (l'**encodage visuel**). Résultat : on compare très bien des **positions alignées** sur un même axe, et mal des **angles**, des **surfaces** ou des **couleurs**.

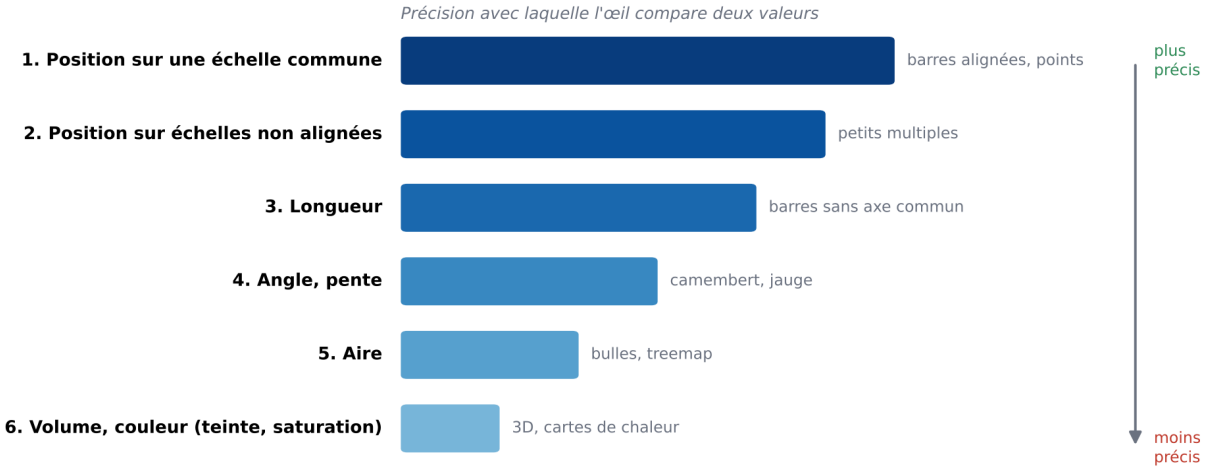
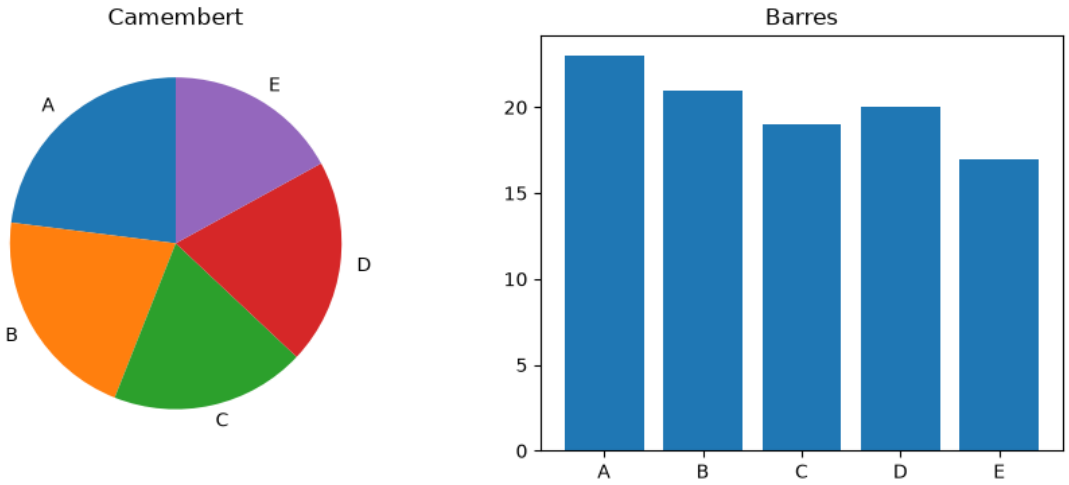


Schéma 2 — La hiérarchie de Cleveland et McGill : plus on est haut, plus la lecture est fiable.

L'expérience du notebook

Les deux dessins montrent **exactement les mêmes chiffres** (A = 23, B = 21, C = 19, D = 20, E = 17).



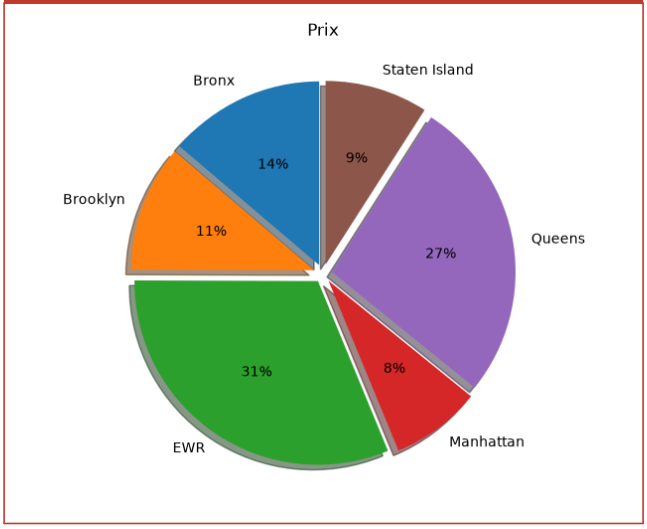
Sur le camembert, impossible de dire si C est plus grand que D. Sur les barres, l'ordre saute aux yeux.

Règle à retenir : pour **comparer** des valeurs, on préfère les **barres** (position sur une échelle commune) au camembert (angle). On se méfie des aires, de la 3D et des couleurs pour porter des quantités.

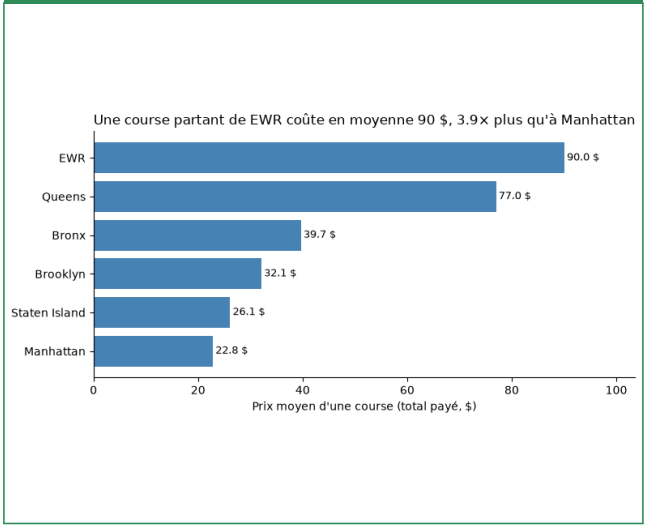
Graphique A

Question visée : dans quel arrondissement une course coûte-t-elle le plus cher en moyenne ?

AVANT — raté



APRÈS — refait



✗ Ce qui ne va pas

- Un camembert montre les **parts d'un tout** : additionner des prix moyens n'a aucun sens, les « % » affichés sont faux.
- Comparer des **angles** est imprécis (6 parts de tailles proches).
- Effets décoratifs (parts écartées, ombre) sans information.
- Pas d'unité ($), pas de valeurs lisibles, catégories non triées.
- Couleurs arbitraires qui ne codent rien.
- Titre « Prix » : un sujet, pas une conclusion.

✓ Choix de la refonte

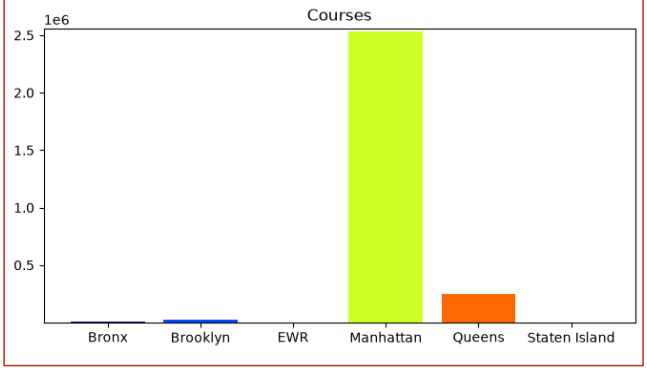
- **Barres horizontales** : position sur une échelle commune.
- **Triées** du plus cher au moins cher.
- Axe qui part de **0**, unité en dollars.
- **Une seule couleur** : la couleur ne code rien ici.
- Valeur écrite au bout de chaque barre.
- **Titre = conclusion**, calculé à partir des données.

Conclusion : une course partant d'EWR (aéroport de Newark) coûte en moyenne **90 $**, soit **3,9×** plus qu'à Manhattan (22,8 $). Attention : EWR et Staten Island ne comptent qu'environ 70 courses chacun, leur moyenne est fragile.

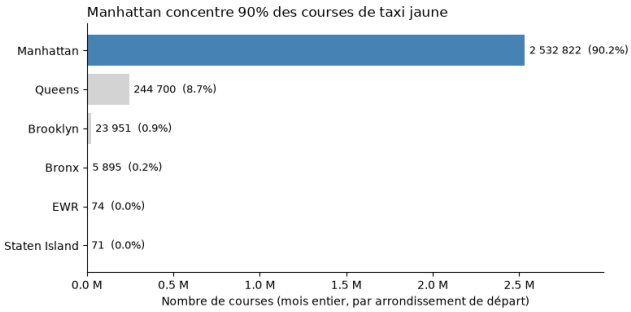
Graphique B

Question visée : quels arrondissements génèrent le plus de courses ?

AVANT — raté



APRÈS — refait



✗ Ce qui ne va pas

- **L'axe Y ne commence pas à zéro** (95 % du minimum) : la longueur des barres ment, les petits arrondissements paraissent nuls.
- Palette **jet** (arc-en-ciel) : couleurs sans sens, illisibles pour une partie des daltoniens.
- Barres non triées, pas d'unité ni de période.
- Titre « Courses » : un sujet, pas une conclusion.

✓ Choix de la refonte

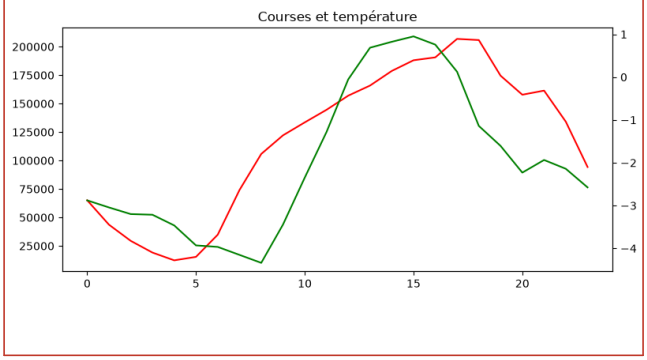
- Barres horizontales **triées**, axe à **0**.
- **Gris + une couleur d'accent** sur la barre qui porte le message.
- Nombre de courses **et part du total (%)** écrits à côté.
- Axe avec unité et période (mois entier).
- Titre qui donne la conclusion.

Conclusion : Manhattan concentre 90 % des courses de taxi jaune (2,5 millions), loin devant le Queens (8,7 %).

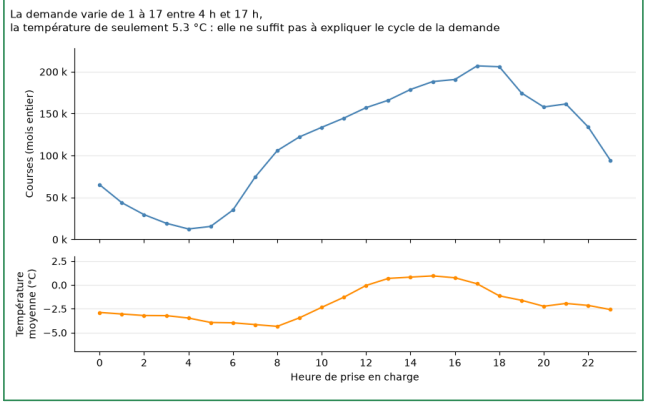
Graphique C

Question visée : la demande de taxis suit-elle la température au fil de la journée ?

AVANT — raté



APRÈS — refait



✗ Ce qui ne va pas

- **Double axe Y** : les deux échelles sont arbitraires, on peut faire « coïncider » n'importe quelles courbes.
- Axe de température **resserré à ±0,2 °C** : 5 °C d'écart paraissent énormes.
- Rouge / vert : indiscernables pour les daltoniens.
- Ni légende, ni libellé d'axe, ni unité.
- Piège : une ressemblance entre deux courbes **ne prouve pas** un lien de cause à effet.

✓ Choix de la refonte

- **Deux panneaux superposés** qui partagent l'axe des heures (« petits multiples ») au lieu d'un double axe.
- Chaque panneau a **son unité** (courses, °C).
- Courses à partir de 0 ; température avec une marge honnête.
- Bleu et orange : distinguables par tous.
- Titre qui dit ce qu'on voit… et ce qu'on ne peut pas conclure.

Conclusion : la demande varie **de 1 à 17** entre 4 h et 17 h, alors que la température ne varie que de **5,3 °C** : elle ne suffit pas à expliquer le cycle de la demande. C'est le rythme de la journée (travail, sorties) qui la pilote.

Anatomie d'un bon graphique

Les cinq règles appliquées dans toutes les refontes, résumées sur un seul exemple :

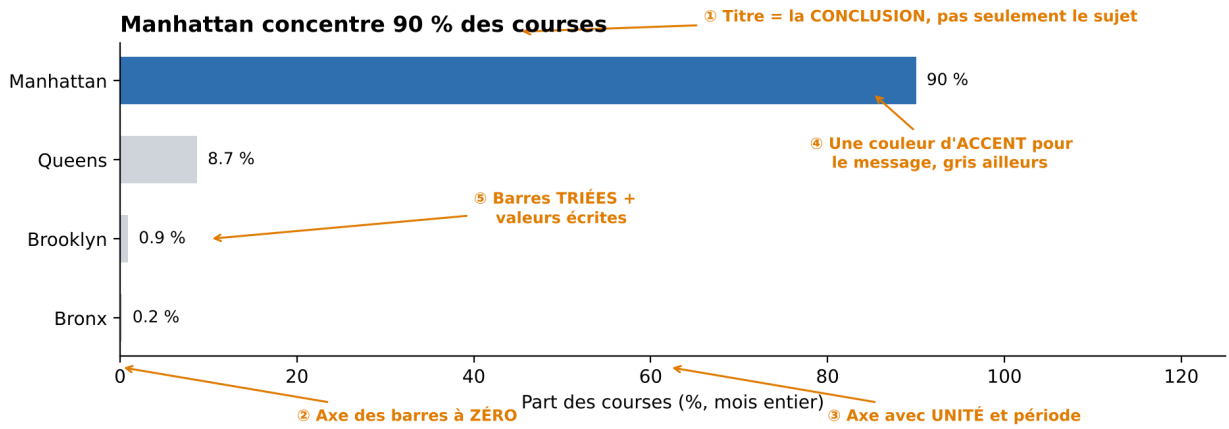
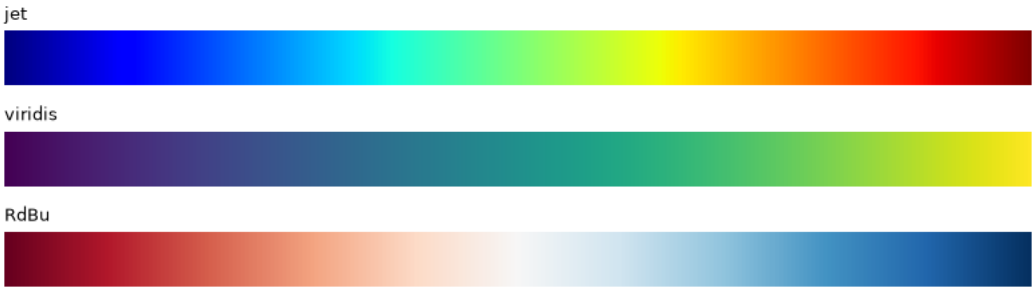


Schéma 3 — Les 5 règles d'un graphique lisible et honnête.

La couleur : trois familles, une à proscrire

Famille	Quand l'utiliser	Exemples
Séquentielle (clair → foncé)	Une quantité qui va de faible à fort	viridis, Blues
Divergente (2 teintes autour d'un centre)	Un écart à une référence (+ / −)	RdBu, PuOr
Catégorielle (teintes distinctes)	Des groupes sans ordre	tab10, Set2
À proscrire	Arc-en-ciel : crée de fausses frontières, illisible pour les daltoniens	jet



jet crée des bandes brutales (cyan, jaune) qui n'existent pas dans les données ; viridis monte régulièrement.

2. Choisir le graphique à partir de la question

On part **toujours de la question**, jamais de l'outil. Le type de question décide du type de graphique :

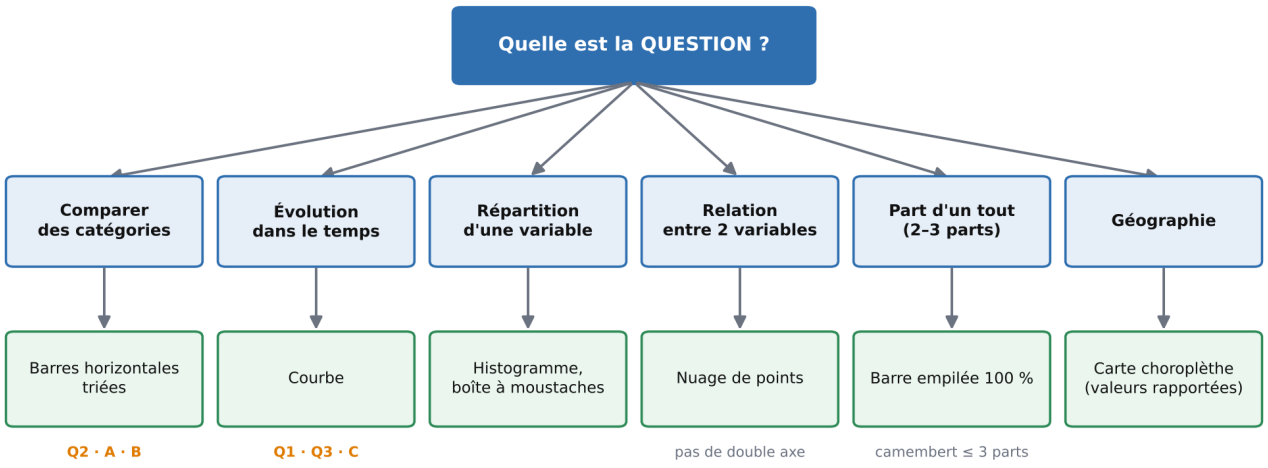
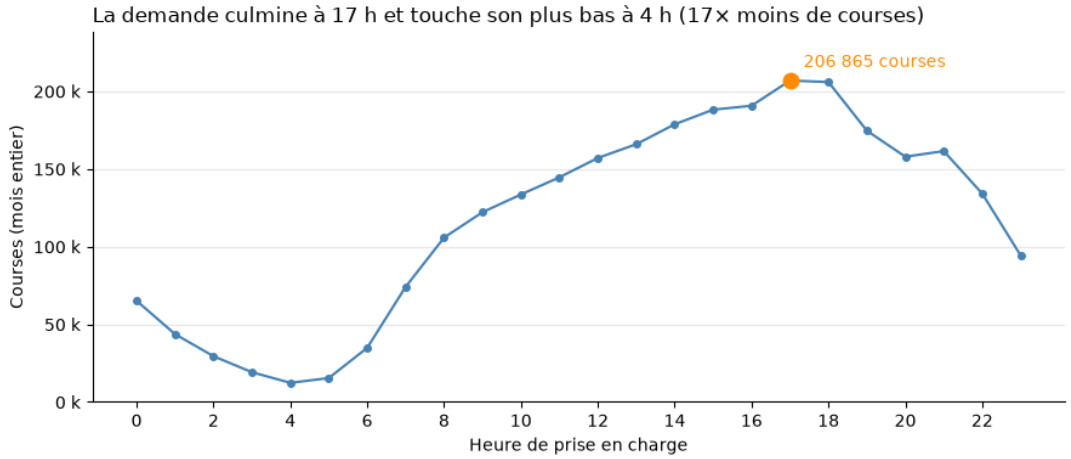


Schéma 4 — De la question au graphique.

Question 1 — À quelle heure la demande est-elle la plus forte ?

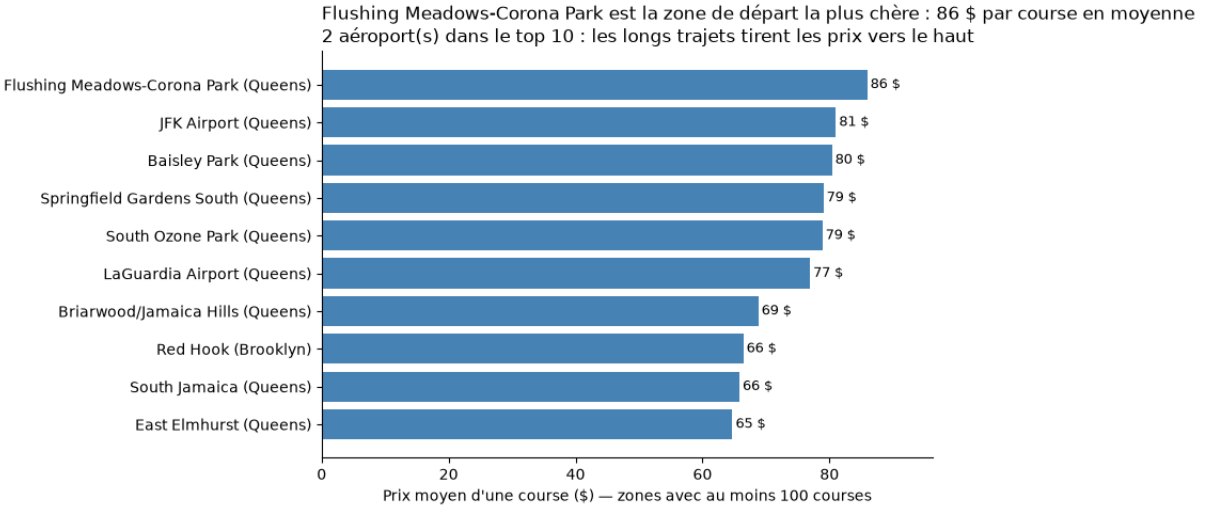
Type : évolution sur la journée → **courbe**, avec le pic en couleur d'accent.



Conclusion : la demande culmine à **17 h** (206 865 courses sur le mois) et touche son plus bas à **4 h** du matin, avec **17× moins** de courses.

Question 2 — Les 10 zones de départ les plus chères

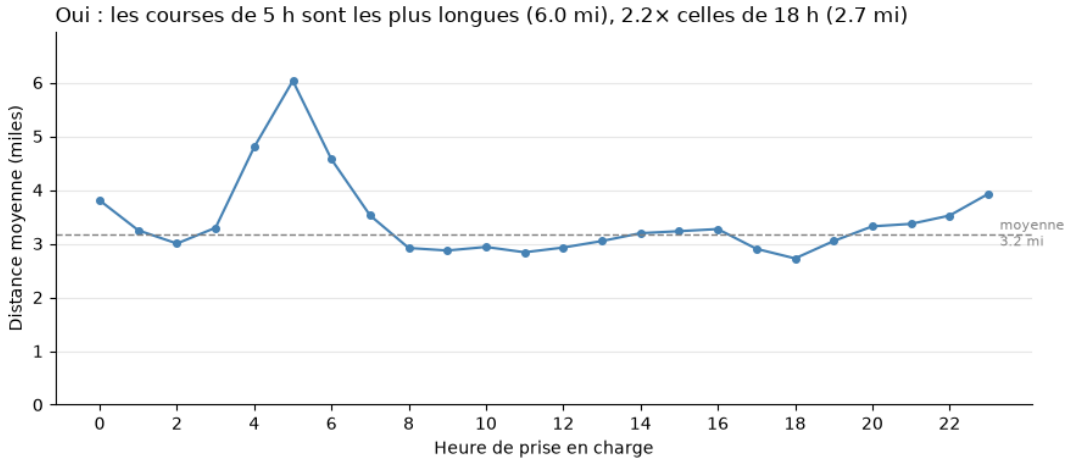
Type : comparaison entre catégories → **barres horizontales triées**, axe à 0. On écarte les zones inconnues et celles de moins de **100 courses** : une moyenne sur 5 courses n'est pas fiable.



Conclusion : Flushing Meadows-Corona Park est la zone la plus chère (**86 $** en moyenne). Le top 10 est presque entièrement dans le **Queens**, avec JFK et LaGuardia : les longs trajets aéroport → Manhattan tirent les prix vers le haut.

Question 3 — La distance moyenne varie-t-elle selon l'heure ?

Type : évolution → **courbe**, avec la moyenne générale en pointillés comme repère.



Conclusion : oui. Les courses de **5 h** du matin sont les plus longues (**6,0 miles**), **2,2×** celles de 18 h (2,7 mi) : tôt le matin, ce sont surtout des trajets vers les aéroports.

3. Les deux pièges rencontrés

Piège n° 1 — Le fuseau horaire

Au premier lancement, les graphiques affichaient un pic de demande à **22 h** et un creux à **9 h**. Le dessin était correct, mais l'histoire était fausse : à New York, la demande est faible la nuit et forte en fin d'après-midi. PostgreSQL renvoyait les horaires en **heure UTC**, pas en heure de New York.

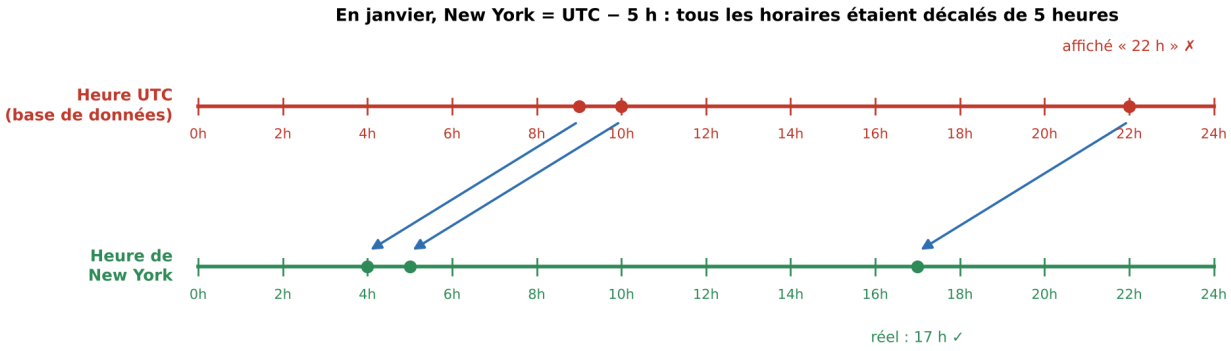


Schéma 5 — Le décalage de 5 heures entre UTC et New York (en janvier).

Correction ajoutée dans la première cellule :

```
horaires["heure_pickup"] = horaires["heure_pickup"]
    .dt.tz_convert("America/New_York").dt.tz_localize(None)
```

tz_convert convertit l'heure UTC en heure de New York ; *tz_localize(None)* retire l'information de fuseau pour garder une heure « simple ».

Leçon : un graphique peut être parfaitement dessiné et pourtant faux. Il faut toujours confronter le résultat au bon sens (« les taxis à 22 h plutôt qu'à 17 h ? »).

Piège n° 2 — La moyenne de moyennes

La table `gold_trajets_horaires` contient déjà une **distance moyenne** par heure et par arrondissement. Faire la moyenne de ces moyennes donnerait le même poids à 10 courses du Queens qu'à 1 000 courses de Manhattan. Il faut **pondérer par le nombre de courses** :

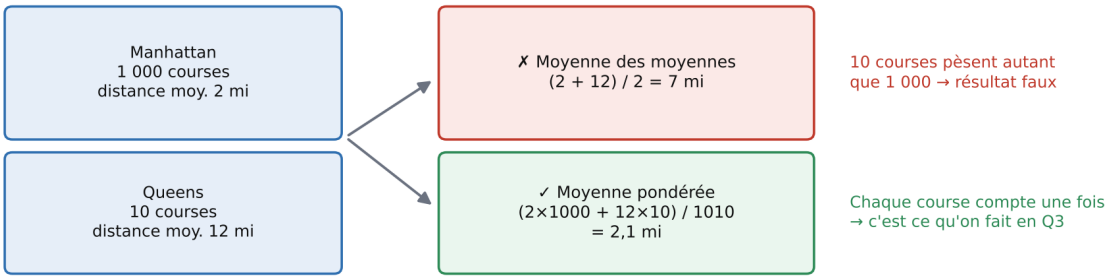


Schéma 6 — Moyenne de moyennes (faux) contre moyenne pondérée (juste).

4. Les commandes utilisées

Toutes se tapent dans **Git Bash**, dans le dossier `cours_dataviz`.

Commande	À quoi elle sert
`git pull upstream main`	Récupère la nouvelle séance publiée par le prof (dépôt « upstream »).
`docker compose up -d`	Démarre Jupyter, PostgreSQL… en arrière-plan (*-d* = detached).
`mkdir -p mon_travail/S04`	Crée le dossier de travail (*-p* : pas d'erreur s'il existe déjà).
`cp seances/S04-perception/04_perception.ipynb mon_travail/`	Copie le notebook du prof : on ne modifie **jamais** `seances/`, sinon le *git pull* bloque.
`git mv ancien nouveau`	Déplace un fichier en prévenant Git (il voit un renommage, pas une suppression).
`git add mon_travail`	Sélectionne le dossier de travail pour la sauvegarde.
`git commit -m "message"`	Crée un point de sauvegarde avec un message.
`git push`	Envoie la sauvegarde sur le fork GitHub (voahangyHts/cours_dataviz).
`docker compose stop`	Arrête les conteneurs en fin de séance. **Rien n'est effacé.**
`docker compose ps`	Liste les conteneurs encore en marche.

Dépannage

Situation	Solution
Git ouvre **Vim** avec « E325: ATTENTION … .MERGE_MSG.swp »	Espace → **D** (supprimer le fichier temporaire) → taper `:wq` + Entrée (enregistrer et quitter).
Éviter Vim à l'avenir	`git config --global core.editor "code --wait"` ou `git pull upstream main --no-edit`
Exécuter tout le notebook	Dans JupyterLab (navigateur, `localhost:8888`) : bouton **double flèche ▶▶** puis **Restart**. Pas dans VS Code.
« 8 commits ahead of laminendao »	Normal : c'est ton travail. Ne jamais cliquer sur « Discard commits ».
À ne pas taper	`docker compose down -v` : supprime la base de données (il faudrait refaire S02).

À RETENIR

1. On part toujours de **la question**, jamais de l'outil.

2. On privilégie la **position sur une échelle commune** (barres, points) ; on se méfie des angles, des aires et de la 3D.

3. Un axe de barres commence à **zéro**.

4. Le titre énonce **la conclusion** ; les axes ont des **unités**.

5. La couleur a un **sens** (séquentielle, divergente, catégorielle) ou n'est pas utilisée.

6. On vérifie que le résultat a du sens : fuseau horaire, petits effectifs, moyenne pondérée.