S05 — Justification des choix de visualisation

Oct 15, 2026 · @RAKOTO

Contexte

L'application Streamlit répond à la question : **où et quand les taxis new-yorkais gagnent-ils le plus ?** Elle lit deux tables gold de PostgreSQL : `gold_trajets_horaires` (courses, revenu, pourboire par heure et par arrondissement) et `gold_zones` (synthèse du mois par zone de départ).

J'y ai ajouté trois fonctionnalités (exercices du notebook 05a) et une vue d'aide à la décision pour le responsable d'exploitation.

Exercice 1 : filtre « jour de la semaine »

Un filtre à choix multiples (lundi → dimanche) dans la barre latérale permet de comparer la semaine et le week-end. Avec seulement samedi et dimanche, on passe de 2 807 513 à 768 249 courses, et la courbe horaire change de forme.

- **Pourquoi une liste à choix multiples :** même composant que le filtre « Arrondissements », donc l'interface reste cohérente. Tous les jours sont cochés par défaut.
- **Limite :** le filtre agit sur les indicateurs et les courbes, mais pas sur la carte ni sur le top 15. Ces vues lisent `gold_zones`, qui ne contient que des totaux sur le mois, sans jour ni heure.

Exercice 2 : le pourboire moyen dépend-il de l'heure ?

Oui, modérément : le pourboire moyen varie d'environ 3,05 $ (vers 7-8 h) à 3,95 $ (vers 10 h), soit près de 30 % d'écart. Il est plus élevé la nuit et en soirée, plus faible en milieu de journée.

- **Pourquoi une courbe :** l'heure est une variable continue et ordonnée (0 → 23). Une ligne montre l'évolution d'une heure à la suivante. Le titre pose directement la question métier.
- **Calcul :** moyenne **pondérée** par le nombre de courses (total des pourboires ÷ total des courses). Une moyenne des moyennes donnerait le même poids à un arrondissement de 10 courses qu'à un de 1 000.
- **Limite de perception :** l'axe vertical commence à 3 $, pas à 0, ce qui amplifie visuellement les écarts.

- **Limite des données :** les heures semblent en UTC (creux d'activité à 10 h, pic à minuit). À New York (UTC − 5 h), le pic à 10 h correspondrait à 5 h du matin, heure locale.

Exercice 3 : carte colorée par le nombre de courses

La carte utilise une échelle de couleurs logarithmique, car le nombre de courses par zone s'étale sur 5 ordres de grandeur : de 1 à plus de 100 000 par mois.

- **En échelle linéaire,** quelques zones très actives (Midtown, Upper East Side, JFK) écrasent l'échelle. Presque toute la carte apparaît dans le même violet et les zones peu actives ne se distinguent plus.
- **En échelle logarithmique,** chaque ordre de grandeur (1, 10, 100, 1 000…) reçoit la même place dans les couleurs. On distingue alors Manhattan et JFK (plus de 10 000 courses), Brooklyn, le Bronx et Queens (100 à 1 000) et Staten Island (moins de 10).
- **Lisibilité :** la légende affiche les vraies valeurs (1, 10, 100…) au lieu des logarithmes, et le survol d'une zone donne son nombre de courses réel.
- **Palette Viridis :** séquentielle et perceptuellement uniforme, elle reste lisible en niveaux de gris et pour les personnes daltoniennes.

Vue ajoutée : où envoyer les chauffeurs ?

Une carte de chaleur croise l'arrondissement (lignes) et l'heure (colonnes). La couleur indique le revenu moyen d'une heure typique. Elle répond à la question : « à cette heure-ci, où y a-t-il le plus d'argent à prendre ? »

Lecture : Manhattan domine à toutes les heures, surtout le soir et la nuit (18 h → 3 h). Queens arrive en 2e position, avec un pic net vers 17 h (aéroports JFK et LaGuardia). Brooklyn, le Bronx, EWR et Staten Island rapportent peu. **Décision :** priorité à Manhattan le soir et la nuit, renfort vers Queens en fin d'après-midi.

Justification du choix (S04) :

- Une carte de chaleur est la forme adaptée pour croiser **deux dimensions** à la fois (lieu × moment).
- Une **seule teinte** (du bleu clair au bleu foncé) se lit naturellement comme une quantité ordonnée : peu → beaucoup.
- Les arrondissements sont **triés par revenu total**, du plus au moins rentable, pour que l'ordre des lignes ait un sens.
- On mesure le **revenu** plutôt que le nombre de courses : une course depuis JFK rapporte environ 80 $, contre environ 20 $ dans Manhattan.

- Le revenu est divisé par le nombre de jours filtrés pour donner un ordre de grandeur concret ($ par heure), et la vue réagit aux filtres jour, heure et arrondissement.

Limites : un revenu total élevé signifie aussi plus de concurrence entre taxis. Une amélioration serait de rapporter ce revenu au nombre de taxis disponibles, ou d'afficher le revenu par course. La couleur linéaire écrase aussi les petits arrondissements, comme pour la carte de l'exercice 3.

Question de réflexion : pourquoi PostgreSQL plutôt que le data lake ?

Le data lake sert à stocker et transformer les données ; PostgreSQL sert de vitrine rapide et fiable où les outils de visualisation viennent se servir.

1. **Rapidité :** les tables gold sont déjà agrégées (quelques milliers de lignes au lieu de millions de trajets). L'application répond immédiatement à chaque filtre, sans recalcul.
2. **Simplicité :** une requête SQL (`pd.read_sql`) suffit. Lire le data lake demanderait Spark et un accès au stockage objet, trop lourd pour une petite application web.
3. **Accès concurrents :** une base de données est conçue pour répondre à plusieurs utilisateurs en même temps, ce qu'exige un tableau de bord partagé.
4. **Séparation des rôles :** le pipeline Spark peut évoluer sans casser l'application, tant que les tables gold gardent la même structure.
5. **Une seule source de vérité :** la couche gold est la version nettoyée et validée. L'application, Power BI ou Grafana affichent donc les mêmes chiffres.